

Trabajo Práctico Final: Anotación de Interacciones entre Lipocalinas y Agrotóxicos

Objetivo

El objetivo de este trabajo práctico es desarrollar una herramienta de línea de comandos (CLI) en Python que, a partir de bibliografía científica, extraiga y estructure información sobre la interacción entre lipocalinas de organismos modelo y agrotóxicos, y luego identifique las proteínas homólogas humanas candidatas que podrían interactuar con estos compuestos.

La herramienta deberá anotar automáticamente datos clave del artículo y enriquecerlos mediante consultas a bases de datos biológicas, generando reportes estructurados que permitan proponer hipótesis sobre qué lipocalinas humanas podrían unir agrotóxicos por convergencia funcional.

Contexto

Las lipocalinas son una familia de proteínas transportadoras de moléculas pequeñas y lipofílicas, caracterizadas por presentar un pliegue de barril- β antiparalelo de ocho hebras que forma una cavidad interna hidrofóbica (Flower et al., 1996). Esta arquitectura les permite unir y transportar una amplia variedad de ligandos endógenos como ácidos grasos, retinoides, hormonas esteroides y feromonas (Grzyb y Latowski, 2021).

En el contexto toxicológico, diversos estudios han demostrado que algunas lipocalinas de organismos no humanos pueden unir agrotóxicos. El pez cebra (*Danio rerio*) es un organismo modelo ampliamente utilizado en estudios toxicológicos y de desarrollo. La exposición a herbicidas como la atrazina, uno de los compuestos más utilizados a nivel mundial, ha sido asociada con efectos adversos en la reproducción y el desarrollo neurológico de peces y anfibios (Fellows et al., 2022). Estos compuestos actúan como disruptores endocrinos y generan estrés oxidativo, pero también se ha documentado que ciertas proteínas, incluyendo lipocalinas, participan en la respuesta celular al herbicida (Wang et al., 2022), facilitando potencialmente su transporte o secuestro en el organismo.

Requerimientos Detallados

La herramienta debe ser una aplicación de línea de comandos (CLI) en Python.

Entrada de datos

La herramienta debe aceptar como entrada un DOI o la ruta a un archivo PDF de un artículo científico que describa la unión de un agrotóxico a una lipocalina en el organismo modelo. Debe soportar también un directorio para procesar múltiples archivos.

Salida

Un archivo JSON por cada artículo procesado, con la información extraída y anotada.

Datos a Extraer del(de los) artículo(s)

La herramienta debe identificar y extraer la siguiente información de cada artículo y enriquecerla con bases de datos externas:

- DOI

- Título
- Autores
- Año de Publicación
- Revista
- B. Proteína del Organismo Modelo:
- Nombre de la proteína (ej. "Proteína quimiosensorial de Apis mellifera").
- Organismo (nombre científico, ej. Apis mellifera o Danio rerio).
- ID de UniProt (obtenido automáticamente por consulta a la API de UniProt usando el nombre de la proteína y el organismo).
- Código PDB (si se menciona una estructura 3D en el artículo o si existe en PDB).
- Función biológica (extraída de UniProt mediante la API).
- C. Agrotóxico(s) Investigado(s):
- Nombre común (ej. Imidacloprid, Atrazina).
- Familia Química (ej. Neonicotinoide, Triazina).
- SMILES (obtenido automáticamente de PubChem mediante la API PUG REST).
- LogP (coeficiente de partición, obtenido de PubChem).
- Tipo de Afinidad: (Kd, Ki, IC50, etc., si están reportados en el texto).
- Valor y Unidad: (ej. 2.5 μ M).
- Método experimental (ej. "ITC", "Fluorescencia", "Docking").
- Fuente del Dato: Texto del artículo, API de BindingDB o ChEMBL.

Búsqueda de Homólogas Humanas

Una vez extraída la información de la proteína del organismo modelo, la herramienta debe realizar los siguientes pasos para identificar proteínas humanas candidatas:

Búsqueda de Homología por Secuencia

Utilizar BLASTp (a través de Biopython o consultando la API de NCBI) para buscar la secuencia de la proteína del organismo modelo contra el proteoma humano (base de datos de referencia de UniProt para Homo sapiens).

Identificar la(s) proteína(s) humana(s) con mayor porcentaje de identidad y cobertura.

Extraer para los mejores 15 hits:

- ID de UniProt Humano.
- Nombre de la Proteína Humana.
- Porcentaje de Identidad de Secuencia.
- Porcentaje de Similitud (considerando sustituciones conservativas).
- E-value.

Tecnologías recomendadas

- Lenguaje: Python
- Librerías de Bioinformática: Biopython (para BLAST y manejo de secuencias), RDKit (opcional, para manejo de SMILES).
- Librerías de Procesamiento de Datos: pandas, requests (para APIs REST).
- Librerías de Parseo de PDFs: PyPDF2, tabula-py
- CLI: argparse o click con un help detallado y bien documentado.
- Empaquetado y Portabilidad: Paquete instalable vía pip (usando setuptools) y/o conda. Debe ser ejecutable dentro de un entorno virtual (venv o conda). (Opcional: contenerización con Docker).

- Documentación: Repositorio GitHub con README.md, Wiki (documentación técnica del proyecto), ejemplos de corrida, y commits frecuentes. Tests unitarios.

Forma de Entrega

El final se entregará via GitHub el día 15 de Julio. El repositorio público en Github deberá contener un archivo README.md con los datos del estudiante, documentación para ejecución e instalación del software. Deben tener múltiples commits. El trabajo será presentado en una exposición oral (con DEMO) el mismo día.

Bibliografía

- Flower, D. R. (1996). The lipocalin protein family: structure and function. *Biochemical Journal*, 318(1), 1-14. doi:10.1042/bj3180001
- Grzyb, J., & Latowski, D. (2021). Lipocalins - a versatile family of proteins. *Postępy Biochemii*, 67(1), 55-64. doi:10.18388/pb.2021_380
- Fellows, C. J., Anderson, T. D., & Swale, D. R. (2022). Acute toxicity of atrazine, alachlor, and chlorpyrifos mixtures to honey bees. *Pesticide Biochemistry and Physiology*, 185, 105135. doi:10.1016/j.pestbp.2022.105135
- Wang, S., et al. (2022). Atrazine exposure in zebrafish induces aberrant genome-wide methylation. *Neurotoxicology and Teratology*, 92, 107095. doi:10.1016/j.ntt.2022.107095